

Errori nei dati di training: impatto sui modelli ML

Progetto di Architetture Dati
Anno accademico 2025-2026

Tommaso Baggio - matricola 912356
Samuele Bergamin - matricola 844861
Andrea Ciacci - matricola 899883

Introduzione:

- Dataset usati
- Metriche
- Modelli ML addestrati
- Aggiunta del rumore

Il nostro progetto tratta di come l'aggiunta di rumore nei dataset influisca sulle performance dei modelli di Machine Learning, prendendo come spunto principale per l'idea il paper:

"Impact of Noise in Dataset on Machine Learning Algorithms".[1]

L'obiettivo principale consiste nel verificare le differenze tra i risultati ottenuti sui dataset originali e sui dataset sporcati.

Dataset usati

Per i nostri esperimenti abbiamo usato **3 dataset differenti**, con numero crescente di righe:

- Liver Patient Dataset;
- Teen Mental Health Dataset;
- Adult Income Dataset.

Le variabili categoriche vengono codificate con **one-hot encoding**.

Metriche

Indicando con TP, TN, FP e FN gli elementi della matrice di confusione, vengono calcolate:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Recall}_1 = \frac{TP}{TP + FN},$$

$$\text{Precision}_1 = \frac{TP}{TP + FP},$$

$$F1_1 = 2 \frac{\text{Precision}_1 \text{ Recall}_1}{\text{Precision}_1 + \text{Recall}_1},$$

$$\text{Balanced Accuracy} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)$$

Modelli ML addestrati

Con ciascun dataset abbiamo addestrato **3 Modelli ML**:

- Decision Tree (DT);
- Neural Network (NN);
- Support Vector Machine (SVM).

Sui dataset viene effettuato uno split (stratificato), in test, training e validation.

Per SVM non abbiamo usato valori ottimizzabili, ma facciamo comunque lo split per omogeneità con gli altri modelli.

Modelli ML addestrati – Decision Tree

Per contenere overfitting con questo modello, abbiamo introdotto alcuni meccanismi:

- **Limitazione della profondità massima** tramite il parametro max depth;
- **Cost-complexity pruning**, che penalizza la complessità strutturale dell'albero;
- **Ottimizzazione del peso da dare agli errori** in base allo sbilanciamento delle classi;

La ricerca dei parametri ottimali avviene tramite **grid search**.

Infine, usiamo la tecnica di **ensemble**: addestriamo 3 alberi su 3 sezioni diverse del dataset, ognuno calcola una soluzione e poi prendiamo il risultato che ha deciso la maggioranza.

Modelli ML addestrati – Neural Network

Per questo modello, abbiamo **normalizzato i dati** con **RobustScaler()**, dalla libreria *sklearn*.

L'architettura è composta da tre livelli densi con rispettivamente **32, 16 e 1 neurone**. I primi due livelli fanno uso di funzione di attivazione **ReLU**, l'ultimo di funzione di attivazione **sigmoide**.

Dal momento che l'addestramento della rete neurale è **stocastico**, l'intero ensemble viene ripetuto $R = 5$ volte per ogni livello di rumore, e poi calcoliamo **media** e **deviazione standard** dei risultati.

Modelli ML addestrati – SVM

Anche per questo modello, abbiamo **normalizzato i dati** con **RobustScaler()**.

Come kernel abbiamo adottato **RBF** (Radial Basis Function), che consente al modello di proiettare implicitamente i dati in uno spazio di dimensione superiore, **rendendo possibile la separazione** anche in presenza di **relazioni non lineari** tra le variabili.

Abbiamo inoltre impostato il parametro **class_weight="balanced"**, al fine di compensare eventuali squilibri tra le classi.

Per ciascun livello vengono costruiti **tre modelli** su campioni bootstrap, e la predizione finale è ottenuta mediante voto di maggioranza sulle classi predette.

Aggiunta del rumore

La nostra strategia consiste nell'andare a modificare le righe originali.

A differenza dell'articolo, però, **andiamo a modificare solamente il training set, lasciando intanto il test set.**

Il rumore viene aggiunto progressivamente, dallo 0% a 100% di righe modificate, con step di 10%.

Il rumore viene applicato in maniera diversa in base al tipo di variabile.

Aggiunta del rumore – Variabili categoriche

Avendo codificato le variabili categoriche in one-hot, la strategia di corruzione consiste nel **disattivare la colonna corrispondente** alla categoria a cui faceva parte in origine la riga, **e attivarne un'altra**.

Aggiunta del rumore – Variabili continue

Anche in questo caso viene selezionata una frazione delle righe del training set, e per ciascun valore selezionato si applica una perturbazione del tipo:

$$\tilde{x}_i = x_i + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2) \quad \sigma = \text{noise_level} \cdot \text{std}(X_{.j})$$

Come valore di noise level, dopo aver sperimentato con diversi valori, abbiamo scelto di usare 0.5.

Aggiunta del rumore – Variabili intere e ordinali

In questo caso, scegliamo una **variazione locale** da applicare, ad esempio, -2, -1, 0, 1, 2, e il risultato viene mantenuto entro limiti espliciti.

Aggiunta del rumore – Strategia

Come metodo di applicazione, le feature sono state ordinate in base al valore di **Mutual Information** rispetto alla variabile target e successivamente **suddivise in due metà**: la prima contenente le feature con Mutual Information più elevata e la seconda quelle con valori inferiori.

Il rumore è stato **applicato separatamente a ciascun gruppo**, mantenendo inalterato l'altro, al fine di valutare come la perturbazione delle feature più o meno informative **influenzi le prestazioni del modello**.

Liver Patient Dataset

- Descrizione Dataset
- Risultati

Il dataset raccoglie informazioni cliniche di pazienti provenienti dalla regione nord-orientale dell'Andhra Pradesh, in India.

Le variabili incluse descrivono caratteristiche demografiche e parametri biochimici correlati alla funzionalità del fegato.


Grazie alla presenza di una variabile target che indica la presenza o meno di una malattia epatica, il dataset rappresenta un valido strumento per studi di classificazione e analisi predittiva in ambito medico.

Liver Patient Dataset – Descrizione

Il dataset è composto da **11 colonne** e **583 righe**.

Nome Variabile	Descrizione
age	Età del paziente
gender	Genere
TB	Livello di bilirubina totale
DB	Livello di bilirubina diretta
alkphos	Livello dell'enzima epatico fosfatasi alcalina
sgpt	Alanina Aminotransferasi (ALT)
sgot	Aspartato Aminotransferasi (AST)
TP	Livello di proteine totali
ALB	Livello di albumina
a/g ratio	Rapporto Albumina/Globuline
Selector	Variabile target (classe di appartenenza)


Liver Patient Dataset – Descrizione



La distribuzione del target è:

71% positivi, 29% negativi.

Liver Patient Dataset – Descrizione




Dalla Mutual Information, otteniamo le 2 metà di feature:

Peggiori: ['Sgpt', 'TP', 'Gender', 'ALB', 'A/G Ratio'].

Migliori: ['Age', 'Sgot', 'Alkphos', 'DB', 'TB']


Liver Patient Dataset – Risultati DT

Sporcando la metà peggiore




Liver Patient Dataset – Risultati DT

Sporcando la metà migliore




Liver Patient Dataset – Risultati NN

Sporcando la metà peggiore




Liver Patient Dataset – Risultati NN

Sporcando la metà migliore




Liver Patient Dataset – Risultati SVM

Sporcando la metà peggiore



Liver Patient Dataset – Risultati SVM

Sporcando la metà migliore



Teen Mental Health Dataset

- Descrizione Dataset
- Risultati

Il dataset raccoglie informazioni relative alla salute mentale degli adolescenti, includendo variabili comportamentali, psicologiche e legate allo stile di vita. Tra queste rientrano l'uso dei social media, la durata del sonno, il rendimento scolastico e i livelli di stress, ansia e depressione.


L'obiettivo principale dei dati è permettere l'analisi delle relazioni tra abitudini quotidiane e condizioni di benessere mentale, evidenziando possibili fattori di rischio o correlazioni significative.

Teen Mental Health Dataset – Descrizione

Il dataset è composto da **13 colonne** e **1200 righe**.

Nome Variabile	Descrizione
age	Età dell'individuo
gender	Genere
daily_social_media_hours	Ore passate sui social
platform_usage	Piattaforma social usata, tra Instagramm e TikTok
sleep_hours	Ore di sonno
screen_time_before_sleep	Tempo passato davanti allo schermo prima di dormire
physical_activity	Ore di attività fisica
social_interaction_level	Livello di interazione sociale
stress_level	Livello di stress
anxiety_level	Livello d'ansia
addiction_level	Livello di dipendenza
depression_label	Diagnosi di depressione


Teen Mental Health Dataset – Descrizione



La distribuzione del target è:

97,46% negativi, 2,58% positivi.

Teen Mental Health Dataset – Descrizione




Dalla Mutual Information, otteniamo le 2 metà di feature:

Peggiori: ['social_interaction_level', 'academic_performance', 'platform_usage', 'screen_time_before_sleep', 'physical_activity', 'addiction_level']


Migliori: ['anxiety_level', 'daily_social_media_hours', 'stress_level', 'sleep_hours', 'age', 'gender']

Teen Mental Health Dataset – Risultati DT

Sporcando la metà peggiore




Teen Mental Health Dataset – Risultati DT




Teen Mental Health Dataset – Risultati NN

Sporcando la metà peggiore




Teen Mental Health Dataset – Risultati NN

Sporcando la metà migliore




Teen Mental Health Dataset – Risultati SVM

Sporcando la metà peggiore



Teen Mental Health Dataset – Risultati SVM

Sporcando la metà migliore



Adult Income Dataset

- Descrizione Dataset
- Risultati

Il dataset vuole mostrare come il reddito annuo di un individuo dipende da diversi fattori.

In modo intuitivo, è influenzato dal livello di istruzione, dall'età, dall'occupazione e così via.


Adult Income Dataset – Descrizione

Il dataset è composto da **15 colonne** e **48842 righe**.

Nome Variabile	Descrizione
age	Età dell'individuo
workclass	Tipo di impiego
fnlwgt	Peso del campione censuario
education	Livello di istruzione, codificato come stringa
educational-num	Livello di istruzione, codificato come numero
marital-status	Stato civile
occupation	Occupazione
relationship	Relazione familiare
race	Razza
gender	Genere
capital-gain	Guadagni di capitale
capital-loss	Perdite di capitale
hours-per-week	Ore lavorate a settimana
native-country	Paese di origine
income	Variabile target (reddito annuo)

*In quanto
ridondante con
'educational-num',
abbiamo rimosso la
feature 'education'.


Adult Income Dataset – Descrizione



La distribuzione del target è:

76% $\leq$ 50K, 24% $>$ 50K.

Adult Income Dataset – Descrizione




Dalla Mutual Information, otteniamo le 2 metà di feature:

Peggiori: ['hours-per-week', 'capital-loss', 'fnlwgt', 'gender', 'workclass', 'native-country', 'race']

Migliori: ['relationship', 'marital-status', 'capital-gain', 'age', 'educational-num', 'occupation', 'hours-per-week']


Adult Income Dataset – Risultati DT

Sporcando la metà peggiore




Adult Income Dataset – Risultati DT

Sporcando la metà migliore




Adult Income Dataset – Risultati NN

Sporcando la metà peggiore




Adult Income Dataset – Risultati NN

Sporcando la metà migliore




Adult Income Dataset – Risultati SVM

Sporcando la metà peggiore



Adult Income Dataset – Risultati SVM

Sporcando la metà migliore



Analisi dei Risultati

- Feature peggiori
contro migliori
- Sensibilità dei modelli
- Suscettibilità dei
dataset



In questa sezione analizzeremo e confronteremo i risultati, evidenziando quelli che ci sembrano più interessanti.

Feature peggiori contro migliori



Analizzando i vari output dei modelli, notiamo che, in generale, **sporcare le feature migliori** porta a una **maggiore instabilità** dei risultati rispetto a sporcare le feature peggiori.

Inoltre, in media, **sporcare le feature migliori** porta a **risultati peggiori** rispetto allo sporcare feature peggiori.

Feature peggiori contro migliori



Feature peggiori contro migliori




Sensibilità dei modelli


Dai nostri test, risulta che il **Decision Tree**, nel caso di Liver Patient Dataset e Teen Mental Health Dataset, è il modello più **sensibile al rumore**, mentre in Adult Income Dataset il modello più sensibile è la **rete neurale**, le cui prestazioni **calano visibilmente** a partire dall'80-90% di rumore applicato.

Sensibilità dei modelli


Confronto tra modelli su Liver Patient Dataset



Confronto tra modelli su Teen Mental Health Dataset



Confronto tra modelli su Adult Income Dataset



Sensibilità dei modelli

Notiamo che l'unico dataset dove i risultati peggiorano sporcando le feature migliori, confrontando i risultati con lo 0% di rumore con quelli con il 100%, risulta essere Adult Income Dataset, che è il dataset con maggior numero di righe.


Infatti, nei **dataset piccoli** (come Liver Patient Dataset e Teen Mental Health Dataset) il rumore ha un effetto più instabile perché **ogni campione ha un peso elevato** e modificare anche pochi dati altera sensibilmente l'informazione complessiva.

Nei **dataset grandi** (come Adult Income Dataset), invece, **lo stesso livello di rumore si distribuisce** su molti più esempi e il suo impatto si attenua, rendendo il modello più stabile.

Un ragionamento simile viene effettuato dal **paper di ispirazione**.

Suscettibilità dei dataset

Inoltre notiamo che, tra i dataset scelti, **Teen Mental Health** sembra essere quello **più sensibile al rumore** (presenta anche più valori di deviazione standard nella più elevati nelle reti neurali).



Suscettibilità dei dataset

Si osserva infine un aspetto rilevante: la **noise injection** è una metodologia ampiamente studiata in letteratura come tecnica di regolarizzazione.

Nei risultati ottenuti, l'introduzione di rumore non porta sempre ad un peggioramento delle prestazioni; al contrario, in diversi casi si osserva un miglioramento delle metriche all'aumentare controllato dell'intensità del rumore. Tale comportamento è coerente con l'interpretazione della noise injection come meccanismo di regolarizzazione, in grado di indurre rappresentazioni più robuste, ridurre l'overfitting su strutture locali potenzialmente non affidabili e favorire una maggiore stabilità del processo di apprendimento. Questo aiuta il modello a non adattarsi troppo ai dettagli del training set e quindi a funzionare meglio anche su dati nuovi, migliorando la capacità di generalizzazione.

Conclusioni

- Possibili sviluppi futuri

In questo progetto abbiamo analizzato come il rumore influisca sull'addestramento di:

- Decision Tree;
- Neural Network;
- SVM

con 3 dataset differenti.

Abbiamo mostrato i vari risultati ottenuti e fatto qualche confronto rilevante.

Possibili sviluppi futuri

Ulteriori esperimenti potrebbero concentrarsi sul **confronto dei risultati ottenuti su dataset di dimensioni simili**, così da valutare l'effetto del rumore indipendentemente dalla dimensione del dataset.

Inoltre, sarebbe interessante estendere l'analisi ad **altri modelli di machine learning** per verificarne il comportamento in presenza di rumore.

Si potrebbero testare anche **diverse modalità di applicazione del rumore**, al fine di individuare strategie diverse.

Infine, si potrebbero testare **altre misure per l'importanza delle feature** per ottenere gruppi di feature da sporcare insieme.

Bibliografia (articolo di riferimento)

[1] Saseendran, A. T., Setia, L., Chhabria, V., Chakraborty, D., & Barman Roy, A. (2019). Impact of noise in dataset on machine learning algorithms. Mach. Learn. Res, 1, 1-8.