

Architetture dati

Errori nei dati di training: impatto sui modelli ML

Tommaso Baggio matricola 912356
Samuele Bergamin matricola 844861
Andrea Ciacci matricola 899883



Anno accademico 2025-2026

Indice

1	Introduzione	3
1.1	Datasets	3
1.2	Modelli ML	4
1.2.1	Decision Tree	4
1.2.2	Neural Network	4
1.2.3	SVM	5
1.3	Noise injection	6
2	Liver Patient Dataset	7
2.1	Descrizione dataset	7
2.2	Risultati	8
2.2.1	Decision Tree	8
2.2.2	Neural Network	10
2.2.3	SVM	13
3	Teen Mental Health Dataset	17
3.1	Descrizione dataset	17
3.2	Risultati	18
3.2.1	Decision Tree	19
3.2.2	Neural Network	21
3.2.3	SVM	23
4	Adult Income Dataset	25
4.1	Descrizione dataset	25
4.2	Risultati	26
4.2.1	Decision Tree	26
4.2.2	Neural Network	29
4.2.3	SVM	32
5	Confronto dati	36
6	Conclusioni	36

1 Introduzione

Il nostro progetto tratta di come l'aggiunta di rumore nei dataset influisca sulle performance dei modelli di Machine Learning, prendendo come spunto principale per l'idea il paper “Impact of Noise in Dataset on Machine Learning Algorithms” (Saseendran, Arun Thundyill, et al, Mach. Learn. Res 1 (2019): 1-8) (reprimibile qui).

L'obiettivo principale consiste nel verificare e giustificare le differenze tra i risultati ottenuti sui dataset originali e sui dataset sporcati.

Per fare ciò, analizziamo 3 dataset distinti, li sporcheremo, e successivamente per ognuno addestreremo 3 diversi modelli: in questo modo, potremo poi confrontare i vari risultati.

1.1 Datasets

Per questo progetto sono stati scelti tre dataset, reperibili su Kaggle.

I dataset che abbiamo scelto sono:

1. Liver Patient Dataset;
2. Teen Mental Health Dataset;
3. Adult Income Dataset.

Questi variano molto in numero di righe, in modo da vedere se anche questo può influire sui risultati.

1.2 Modelli ML

Per avere una idea più chiara di come il rumore influisce sulle prestazioni, abbiamo addestrato 3 diversi modelli.

1.2.1 Decision Tree

Il primo modello che abbiamo preso in considerazione è il Decision Tree, in quanto dà risultati interpretabili e ottiene una elevata velocità di addestramento e inferenza.

Per contenere l'overfitting abbiamo introdotto due meccanismi principali:

- Il primo è la limitazione della profondità massima tramite il parametro `max_depth`, che impedisce all'albero di ramificarsi oltre un certo livello;
- Il secondo è il *cost-complexity pruning*, che penalizza la complessità strutturale dell'albero introducendo il parametro α nella funzione obiettivo:

$$\mathcal{L}_\alpha(T) = \text{errore}(T) + \alpha \cdot |T| \quad (1)$$

dove $|T|$ indica il numero di foglie dell'albero T . Valori più elevati di α producono alberi più potati e quindi più semplici.

La scelta dei valori ottimali di `max_depth` e `ccp_alpha` avviene tramite una ricerca a griglia sui valori candidati, selezionando la configurazione che massimizza la metrica scelta sul test set.

Oltre a questi parametri, si ottimizza il peso da dare agli errori in base allo sbilanciamento delle classi.

Successivamente, abbiamo fatto uso di *undersampling*, una strategia che prevede di prendere un numero di righe ridotto per la classe maggioritaria, in modo da avere un training set bilanciato.

Per ottenere risultati ancora più stabili, usiamo anche la tecnica di *ensemble*: addestriamo 3 alberi su 3 sezioni diverse del dataset, ognuno calcola una soluzione e poi prendiamo il risultato che ha scelto la maggioranza.

1.2.2 Neural Network

Il secondo modello addestrato per ciascun dataset è una rete neurale, scelta per la sua capacità di apprendere rappresentazioni complesse dei dati e modellare relazioni non lineari tra le variabili. Grazie a queste caratteristiche, risulta generalmente robusta anche in presenza di rumore nei dati.

Per la fase di normalizzazione è stato utilizzato `RobustScaler()` (dalla libreria `sklearn`), ritenuto più adatto alla struttura dei dataset rispetto ad altri metodi di scaling come `StandardScaler()`. A differenza della standardizzazione basata su media e deviazione standard, `RobustScaler` utilizza la mediana e l'intervallo interquartile (IQR), risultando meno sensibile alla presenza di valori anomali (*outlier*).

Per le reti abbiamo usato la libreria `tensorflow` e `keras`.

La funzione `build_model(input_dim)` si occupa della costruzione della rete neurale, definendo un'architettura composta da tre livelli densi con rispettivamente 32, 16 e 1 neurone. L'ultimo livello utilizza una funzione di attivazione sigmoide, poiché i dataset affrontano un problema di classificazione binaria e l'output rappresenta una probabilità compresa tra 0 e 1.

Una volta definita l'architettura, il modello viene compilato e successivamente addestrato utilizzando una `batch_size` pari a 32.

Anche in questo caso viene adottato un approccio di ensemble, addestrando tre reti neurali distinte. In fase di inferenza, ciascun modello produce una probabilità di appartenenza alla classe positiva; tali probabilità vengono mediate e la classificazione finale è ottenuta applicando una soglia pari a 0.5 alla probabilità media.

1.2.3 SVM

Il terzo modello utilizzato per ciascun dataset è una Support Vector Machine (SVM), scelta per la sua efficacia nei problemi di classificazione binaria e per la capacità di costruire frontiere di decisione non lineari tramite l'utilizzo di kernel. In particolare, è stato adottato un kernel RBF (Radial Basis Function), che consente al modello di proiettare implicitamente i dati in uno spazio di dimensione superiore, rendendo possibile la separazione anche in presenza di relazioni non lineari tra le variabili.

Per la normalizzazione dei dati è stato utilizzato nuovamente `RobustScaler()`.

L'implementazione è stata realizzata tramite la libreria `scikit-learn`, utilizzando la classe `SVC`. Il modello è stato configurato con il parametro `class_weight = "balanced"`, al fine di compensare eventuali squilibri tra le classi e ridurre il rischio di bias verso la classe maggioritaria, soprattutto nelle condizioni di elevato rumore nei dati.

Per ciascun livello di rumore viene addestrato un ensemble composto da tre SVM indipendenti. La diversificazione tra i modelli è ottenuta mediante bootstrap del training set, cioè tramite campionamento con reinserimento dei dati disponibili. In fase di inferenza, ciascun modello dell'ensemble produce una predizione di classe e il risultato finale viene determinato come media delle predizioni binarie e successiva applicazione di una soglia pari a 0.5.

1.3 Noise injection

La nostra strategia consiste nell'andare a modificare le righe originali. A differenza dell'articolo, però, andiamo a modificare solamente il training set, lasciando intatto il test set.

Il rumore viene aggiunto progressivamente, dallo 0% a 100% di righe modificate, con step di 10%.

Il rumore viene applicato diversamente se parliamo di feature continua o categoria:

- **Variabili categoriche:** La funzione `corrupt_rows_cat` implementa una strategia di *random replacement*. Dopo aver selezionato una frazione ρ delle righe del dataset, per ciascuna osservazione corrotta si procede alla sostituzione del valore originale con un altro valore estratto casualmente dall'insieme dei valori osservati nella stessa colonna;
- **Variabili continue:** La funzione `corrupt_rows_cont` introduce invece rumore additivo gaussiano sulle variabili numeriche. Anche in questo caso viene selezionata una frazione ρ delle righe del training set, e per ciascun valore selezionato si applica una perturbazione del tipo:

$$\tilde{x}_i = x_i + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

dove la deviazione standard del rumore è definita come:

$$\sigma = \text{noise_level} \cdot \text{std}(X_{.j})$$

in cui $\text{std}(X_{.j})$ rappresenta la deviazione standard empirica della colonna considerata. Questo rende il rumore adattivo alla scala della variabile, evitando distorsioni non proporzionate.

Come valore di `noise_level`, dopo aver sperimentato con diversi valori, abbiamo scelto di usare 0.5.

Come metodo di applicazione, le feature sono state ordinate in base al valore di Mutual Information rispetto alla variabile target e successivamente suddivise in due gruppi: il primo contenente le feature con Mutual Information più elevata e il secondo quelle con valori inferiori. Il rumore è stato applicato separatamente a ciascun gruppo, mantenendo inalterato l'altro, al fine di valutare come la perturbazione delle feature più o meno informative influenzi le prestazioni del modello.

2 Liver Patient Dataset


Il dataset raccoglie informazioni cliniche di pazienti provenienti dalla regione nord-orientale dell'Andhra Pradesh, in India. Le variabili incluse descrivono caratteristiche demografiche e parametri biochimici correlati alla funzionalità del fegato. Grazie alla presenza di una variabile target che indica la presenza o meno di una malattia epatica, il dataset rappresenta un valido strumento per studi di classificazione e analisi predittiva in ambito medico.

2.1 Descrizione dataset


Il dataset è composto da **11 colonne** e **583 righe**.

Nome Variabile	Descrizione
age	Età del paziente
gender	Genere
TB	Livello di bilirubina totale
DB	Livello di bilirubina diretta
alkphos	Livello dell'enzima epatico fosfatasi alcalina
sgpt	Alanina Aminotransferasi (ALT)
sgot	Aspartato Aminotransferasi (AST)
TP	Livello di proteine totali
ALB	Livello di albumina
a/g ratio	Rapporto Albumina/Globuline
Selector	Variabile target (classe di appartenenza)

La distribuzione del target è: **71% positivi**, **29% negativi**.



Attraverso il calcolo della Mutual Information per le varie feature, otteniamo una classifica, dalla più importante alla meno importante.



2.2 Risultati

2.2.1 Decision Tree

Per valutare la robustezza del Decision Tree, il rumore viene applicato alle feature **Alkphos**, **ALB**, **A/G Ratio**, **Gender** e **TP**. Le prime tre e **TP** sono variabili continue, mentre **Gender** è una variabile categorica. La Tabella 1 riporta le prestazioni di riferimento ottenute sul dataset non corrotto, cioè con rumore pari allo 0%.

La migliore configurazione individuata utilizza una profondità massima pari a 5, nessuna potatura cost-complexity (`ccp_alpha` = 0) e pesi di classe 1 e 5 rispettivamente per le classi 0 e 1. Questa scelta privilegia il riconoscimento della classe positiva: il recall della classe 1 raggiunge infatti 0.94, a fronte di una precision pari a 0.4234.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)	Macro F1
0%	0.6171	0.7140	0.4234	0.9400	0.5839	0.6147

Tabella 1: Prestazioni del Decision Tree sul Liver Patient Dataset senza rumore.

La matrice di confusione è $\begin{bmatrix} 61 & 64 \\ 3 & 47 \end{bmatrix}$: su 50 osservazioni della classe 1, il modello ne identifica correttamente 47, ma assegna erroneamente alla classe positiva

64 delle 125 osservazioni della classe 0. Ne deriva una balanced accuracy superiore all'accuracy complessiva, coerentemente con l'enfasi posta sulla classe minoritaria mediante i pesi di classe.




Figura 1: Robustezza dell'ensemble di Decision Tree al crescere del rumore applicato alle feature **Alkphos**, **ALB**, **A/G Ratio**, **Gender** e **TP**.

Come mostrato in Figura 1, fino al 90% di rumore le metriche oscillano in intervalli contenuti e il recall della classe 1 rimane elevato, indicando una buona robustezza dell'ensemble. Al 100% il recall cala nettamente, mentre accuracy e precision aumentano: il modello diventa quindi meno orientato alla classe positiva e produce un miglior bilanciamento tra le predizioni, senza però migliorare l'F1-score.




Figura 2: Robustezza dell'ensemble di Decision Tree al crescere del rumore applicato alle feature continue Age, Sgot, TB, Sgpt e DB.

La Figura 2 mostra un andamento più irregolare rispetto al gruppo precedente: il recall della classe 1 diminuisce sensibilmente già al 10% di rumore e presenta forti oscillazioni, segnalando una maggiore dipendenza del modello da queste feature. Accuracy e balanced accuracy restano relativamente stabili, ma la riduzione finale dell'F1-score conferma che tale stabilità non corrisponde a una capacità altrettanto costante di riconoscere la classe positiva.

Nel complesso, il confronto tra i due grafici mostra che l'ensemble tollera bene il rumore applicato alle feature meno informative, mentre risulta più sensibile alla corruzione di Age, Sgot, TB, Sgpt e DB, caratterizzate da una maggiore Mutual Information rispetto al target. La relativa stabilità di accuracy e balanced accuracy non deve quindi essere interpretata, da sola, come prova di robustezza: le oscillazioni del recall e la riduzione dell'F1-score evidenziano un peggioramento nel riconoscimento della classe positiva. Inoltre, la precision generalmente contenuta indica che l'elevato recall viene ottenuto al costo di numerosi falsi positivi; per questo motivo recall e F1-score della classe 1 risultano le metriche più significative per valutare il comportamento del modello.

2.2.2 Neural Network

Per il primo esperimento sulla rete neurale, il rumore è stato applicato alle feature Alkphos, ALB, A/G Ratio, Gender e TP, con livelli crescenti dallo 0% al

100%. La Tabella 2 riporta le metriche ottenute dall'ensemble di tre reti per ciascun livello di corruzione.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.6857	0.4980	0.2727	0.0600	0.0984
10%	0.7029	0.4920	0.0000	0.0000	0.0000
20%	0.7029	0.4920	0.0000	0.0000	0.0000
30%	0.6800	0.5420	0.3929	0.2200	0.2821
40%	0.7257	0.5500	0.5833	0.1400	0.2258
50%	0.6914	0.4960	0.2500	0.0400	0.0690
60%	0.6914	0.5140	0.3571	0.1000	0.1563
70%	0.7200	0.5580	0.5294	0.1800	0.2687
80%	0.7086	0.5380	0.4667	0.1400	0.2154
90%	0.7429	0.5920	0.6316	0.2400	0.3478
100%	0.7086	0.5620	0.4783	0.2200	0.3014

Tabella 2: Prestazioni dell'ensemble di reti neurali al crescere del rumore sulle feature Alkphos, ALB, A/G Ratio, Gender e TP.




Figura 3: Robustezza dell'ensemble di reti neurali al crescere del rumore applicato alle feature Alkphos, ALB, A/G Ratio, Gender e TP.

Come evidenziato dalla Figura 3, l'accuracy rimane compresa tra 0.68 e 0.74, ma questo andamento nasconde una capacità molto limitata di riconoscere la classe positiva. Con rumore pari al 10% e al 20%, precision, recall e F1-score

della classe 1 sono infatti nulli: l'ensemble non identifica alcun campione positivo e tende a predire prevalentemente la classe maggioritaria.

Le metriche della classe 1 migliorano ai livelli di rumore più elevati e raggiungono il valore massimo al 90%, con un F1-score pari a 0.3478. Tale risultato non dimostra tuttavia che il rumore favorisca la rete neurale: poiché l'addestramento è stocastico, le oscillazioni possono dipendere dall'inizializzazione dei pesi e dal campionamento. Per sostenere questa ipotesi sarebbero necessarie più esecuzioni per ogni livello di rumore, riportando media e variabilità delle metriche. In questo esperimento, balanced accuracy, recall e F1-score risultano pertanto più rappresentativi dell'accuracy complessiva.

Il secondo esperimento considera invece le feature continue **Age**, **Sgot**, **TB**, **Sgpt** e **DB**. I risultati completi sono riportati nella Tabella 3.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.7143	0.5480	0.5000	0.1600	0.2424
10%	0.6914	0.5200	0.3750	0.1200	0.1818
20%	0.6971	0.4940	0.2000	0.0200	0.0364
30%	0.7029	0.4920	0.0000	0.0000	0.0000
40%	0.7200	0.5220	0.6000	0.0600	0.1091
50%	0.6914	0.4900	0.1667	0.0200	0.0357
60%	0.6971	0.5120	0.3636	0.0800	0.1311
70%	0.7086	0.4960	0.0000	0.0000	0.0000
80%	0.6743	0.5080	0.3158	0.1200	0.1739
90%	0.6914	0.5200	0.3750	0.1200	0.1818
100%	0.6514	0.6840	0.4368	0.7600	0.5547

Tabella 3: Prestazioni dell'ensemble di reti neurali al crescere del rumore sulle feature **Age**, **Sgot**, **TB**, **Sgpt** e **DB**.




Figura 4: Robustezza dell'ensemble di reti neurali al crescere del rumore applicato alle feature continue Age, Sgot, TB, Sgpt e DB.

La Figura 4 evidenzia prestazioni molto instabili sulla classe positiva: tra il 20% e il 90% di rumore il recall rimane quasi sempre prossimo allo zero e si annulla completamente al 30% e al 70%. Al 100% si osserva invece un aumento improvviso del recall fino a 0.76 e dell'F1-score fino a 0.5547, accompagnato da una riduzione dell'accuracy complessiva; questo punto anomalo non è sufficiente per concludere che la corruzione totale migliori il modello.

ATTENZIONE: RISULTATI DA VERIFICARE PRIMA DELLA VERSIONE FINALE

Le baseline allo 0% dei due esperimenti sulla rete neurale non coincidono, nonostante il training set non sia ancora corrotto. Il campionamento bootstrap usa `np.random.choice` senza fissare esplicitamente il seed di NumPy; pertanto sia questa differenza sia il miglioramento anomalo osservato al 100% potrebbero dipendere dalla casualità dell'addestramento. Occorre fissare tutti i seed, rieseguire entrambi gli esperimenti più volte e sostituire questi risultati con media e deviazione standard.

2.2.3 SVM

Per il primo esperimento con la SVM, il rumore è stato applicato alle feature Alkphos, ALB, A/G Ratio, Gender e TP. Per ogni livello di corruzione sono state

addestrate tre SVM su campioni bootstrap differenti; la predizione finale è stata ottenuta mediante voto di maggioranza. I risultati sono riportati nella Tabella 4.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.5371	0.6460	0.3719	0.9000	0.5263
10%	0.5886	0.6820	0.4018	0.9000	0.5556
20%	0.5257	0.6380	0.3659	0.9000	0.5202
30%	0.5314	0.6420	0.3689	0.9000	0.5233
40%	0.5257	0.6560	0.3721	0.9600	0.5363
50%	0.5200	0.6520	0.3692	0.9600	0.5333
60%	0.5200	0.6340	0.3629	0.9000	0.5172
70%	0.5600	0.6620	0.3846	0.9000	0.5389
80%	0.5486	0.6540	0.3782	0.9000	0.5325
90%	0.5086	0.6440	0.3636	0.9600	0.5275
100%	0.5943	0.6860	0.4054	0.9000	0.5590

Tabella 4: Prestazioni dell'ensemble di SVM al crescere del rumore sulle feature Alkphos, ALB, A/G Ratio, Gender e TP.




Figura 5: Robustezza dell'ensemble di SVM al crescere del rumore applicato alle feature Alkphos, ALB, A/G Ratio, Gender e TP.

Come mostra la Figura 5, le prestazioni non presentano un deterioramento progressivo al crescere del rumore. Il recall della classe 1 rimane molto elevato

e stabile, con valori compresi tra 0.90 e 0.96, mentre balanced accuracy e F1-score oscillano rispettivamente intorno a 0.65 e 0.53. L'ensemble risulta quindi robusto alla corruzione di questo gruppo di feature.

La precision rimane tuttavia compresa tra 0.36 e 0.41: l'elevato recall è ottenuto classificando come positivi numerosi campioni della classe 0, con una conseguente quantità rilevante di falsi positivi. Anche in questo caso l'accuracy complessiva, variabile tra 0.51 e 0.59, non descrive adeguatamente il comportamento del classificatore sulle due classi.

Nel secondo esperimento il rumore è stato applicato alle feature continue Age, Sgot, TB, Sgpt e DB. La Tabella 5 riporta le metriche ottenute.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.5943	0.6800	0.4037	0.8800	0.5535
10%	0.5829	0.6720	0.3964	0.8800	0.5466
20%	0.5771	0.6620	0.3909	0.8600	0.5375
30%	0.5143	0.6300	0.3600	0.9000	0.5143
40%	0.4857	0.6040	0.3438	0.8800	0.4944
50%	0.5029	0.6100	0.3496	0.8600	0.4971
60%	0.4857	0.6040	0.3438	0.8800	0.4944
70%	0.4857	0.6100	0.3462	0.9000	0.5000
80%	0.5486	0.6480	0.3761	0.8800	0.5269
90%	0.4686	0.5860	0.3333	0.8600	0.4804
100%	0.4743	0.6020	0.3409	0.9000	0.4945

Tabella 5: Prestazioni dell'ensemble di SVM al crescere del rumore sulle feature Age, Sgot, TB, Sgpt e DB.




Figura 6: Robustezza dell'ensemble di SVM al crescere del rumore applicato alle feature continue Age, Sgot, TB, Sgpt e DB.

La Figura 6 mostra che il recall della classe 1 rimane elevato, tra 0.86 e 0.90, anche con forti livelli di corruzione. Al contrario, accuracy, balanced accuracy, precision e F1-score presentano una tendenza complessivamente decrescente: rispetto alla condizione senza rumore, al 100% l'accuracy passa da 0.5943 a 0.4743 e l'F1-score da 0.5535 a 0.4945.

Il confronto tra i due gruppi suggerisce quindi che la SVM sia meno sensibile al rumore applicato a Alkphos, ALB, A/G Ratio, Gender e TP. La corruzione di Age, Sgot, TB, Sgpt e DB riduce invece la capacità di distinguere correttamente le due classi, pur mantenendo alta la copertura della classe positiva. Anche in questo esperimento la precision contenuta segnala la presenza di numerosi falsi positivi.

ATTENZIONE: RIPRODUCIBILITÀ DEI RISULTATI SVM

Il campionamento bootstrap dell'ensemble utilizza `np.random.choice` senza fissare esplicitamente il seed di NumPy. Prima della versione finale è necessario fissare il seed e rieseguire entrambi gli esperimenti, preferibilmente più volte, riportando media e deviazione standard delle metriche.

3 Teen Mental Health Dataset

Il dataset raccoglie informazioni relative alla salute mentale degli adolescenti, includendo variabili comportamentali, psicologiche e legate allo stile di vita. Tra queste rientrano l'uso dei social media, la durata del sonno, il rendimento scolastico e i livelli di stress, ansia e depressione.


L'obiettivo principale dei dati è permettere l'analisi delle relazioni tra abitudini quotidiane e condizioni di benessere mentale, evidenziando possibili fattori di rischio o correlazioni significative.

3.1 Descrizione dataset


Il dataset è composto da **13 colonne** e **1200 righe**.

Nome Variabile	Descrizione
age	Età dell'individuo
gender	Genere
daily_social_media_hours	Ore passate sui social
platform_usage	Piattaforma social usata, tra Instagramm e TikTok
sleep_hours	Ore di sonno
screen_time_before_sleep	Tempo passato davanti allo schermo prima di dormire
physical_activity	Ore di attività fisica
social_interaction_level	Livello di interazione sociale
stress_level	Livello di stress
anxiety_level	Livello d'ansia
addiction_level	Livello di dipendenza
depression_label	Diagnosi di depressione

La distribuzione del target è: **97,46% negativi**, **2,58% positivi**.



Attraverso il calcolo della Mutual Information per le varie feature, otteniamo una classifica, dalla più importante alla meno importante.



3.2 Risultati


Abbiamo diviso le feature in 2 metà in base alla Mutual Information:

- **Peggiori:** academic_performance, age, platform_usage, screen_time_before_sleep, physical_activity, social_interaction_level.
- **Migliori:** anxiety_level, stress_level, daily_social_media_hours, sleep_hours, addiction_level, gender.

Per ogni modello, abbiamo sporcato progressivamente il dataset e monitorato le prestazioni.

3.2.1 Decision Tree


Robustezza ensemble alberi su ['academic_performance', 'age', 'platform_usage', 'screen_time_before_sleep', 'physical_activity', 'social_interaction_level']



% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9944	0.8889	1.0000	0.7778	0.8750
10	0.9944	0.8889	1.0000	0.7778	0.8750
20	0.9944	0.8889	1.0000	0.7778	0.8750
30	0.9944	0.8889	1.0000	0.7778	0.8750
40	0.9944	0.8889	1.0000	0.7778	0.8750
50	0.9944	0.8889	1.0000	0.7778	0.8750
60	0.9944	0.8889	1.0000	0.7778	0.8750
70	0.9944	0.8889	1.0000	0.7778	0.8750
80	0.9944	0.8889	1.0000	0.7778	0.8750
90	0.9944	0.8889	1.0000	0.7778	0.8750
100	0.9944	0.8889	1.0000	0.7778	0.8750

Tabella 6: Risultati ottenuti dal Decision Tree sporcando le feature peggiori


Robustezza ensemble alberi su ['anxiety_level', 'stress_level', 'daily_social_media_hours', 'sleep_hours', 'addiction_level', 'gender']



% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9944	0.8889	1.0000	0.7778	0.8750
10	0.9972	0.9444	1.0000	0.8889	0.9412
20	0.9889	0.7778	1.0000	0.5556	0.7143
30	0.9667	0.8205	0.4000	0.6667	0.5000
40	0.9722	0.6068	0.4000	0.2222	0.2857
50	0.9667	0.8205	0.4000	0.6667	0.5000
60	0.9833	0.6667	1.0000	0.3333	0.5000
70	0.9528	0.8134	0.3000	0.6667	0.4138
80	0.9528	0.6510	0.2143	0.3333	0.2609
90	0.9806	0.6111	1.0000	0.2222	0.3636
100	0.9806	0.6652	0.7500	0.3333	0.4615

Tabella 7: Risultati ottenuti dal Decision Tree sporcando le feature migliori


3.2.2 Neural Network



% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9750	0.6083	0.5000	0.2222	0.3077
10	0.9722	0.6068	0.4000	0.2222	0.2857
20	0.9833	0.6667	1.0000	0.3333	0.5000
30	0.9889	0.7778	1.0000	0.5556	0.7143
40	0.9806	0.7194	0.6667	0.4444	0.5333
50	0.9778	0.6097	0.6667	0.2222	0.3333
60	0.9833	0.7208	0.8000	0.4444	0.5714
70	0.9806	0.6111	1.0000	0.2222	0.3636
80	0.9778	0.7721	0.5556	0.5556	0.5556
90	0.9833	0.8291	0.6667	0.6667	0.6667
100	0.9806	0.6652	0.7500	0.3333	0.4615

Tabella 8: Risultati ottenuti dalla NN sporcando le feature peggiori

Robustezza NN ensemble su ['anxiety_level', 'stress_level', 'daily_social_media_hours', 'sleep_hours', 'addiction_level', 'gender']




% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9806	0.7735	0.6250	0.5556	0.5882
10	0.9750	0.6624	0.5000	0.3333	0.4000
20	0.9778	0.6638	0.6000	0.3333	0.4286
30	0.9833	0.7208	0.8000	0.4444	0.5714
40	0.9750	0.5541	0.5000	0.1111	0.1818
50	0.9750	0.5000	0.0000	0.0000	0.0000
60	0.9806	0.6111	1.0000	0.2222	0.3636
70	0.9750	0.5000	0.0000	0.0000	0.0000
80	0.9778	0.6097	0.6667	0.2222	0.3333
90	0.9750	0.5000	0.0000	0.0000	0.0000
100	0.9750	0.5000	0.0000	0.0000	0.0000

Tabella 9: Risultati ottenuti dalla NN sporcando le feature migliori

3.2.3 SVM


Robustezza SVM ensemble su ['academic_performance', 'age', 'platform_usage', 'screen_time_before_sleep', 'physical_activity', 'social_interaction_level']



% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9306	0.9644	0.2647	1.0000	0.4186
10	0.9278	0.9630	0.2571	1.0000	0.4091
20	0.9500	0.9744	0.3333	1.0000	0.5000
30	0.9333	0.9658	0.2727	1.0000	0.4286
40	0.9444	0.9715	0.3103	1.0000	0.4737
50	0.9333	0.9658	0.2727	1.0000	0.4286
60	0.9333	0.9658	0.2727	1.0000	0.4286
70	0.9417	0.9701	0.3000	1.0000	0.4615
80	0.9306	0.9644	0.2647	1.0000	0.4186
90	0.9278	0.9630	0.2571	1.0000	0.4091
100	0.9500	0.8661	0.3043	0.7778	0.4375

Tabella 10: Risultati ottenuti dalla SVM sporcando le feature peggiori

Robustezza SVM ensemble su ['anxiety_level', 'stress_level', 'daily_social_media_hours', 'sleep_hours', 'addiction_level', 'gender']



% Rumore	Accuracy	Balanced Acc.	Precision	Recall	F1
0	0.9389	0.9687	0.2903	1.0000	0.4500
10	0.9556	0.9772	0.3600	1.0000	0.5294
20	0.9111	0.9544	0.2195	1.0000	0.3600
30	0.9111	0.9544	0.2195	1.0000	0.3600
40	0.8417	0.9188	0.1364	1.0000	0.2400
50	0.8944	0.9459	0.1915	1.0000	0.3214
60	0.9222	0.8519	0.2121	0.7778	0.3333
70	0.9250	0.9074	0.2353	0.8889	0.3721
80	0.8417	0.9188	0.1364	1.0000	0.2400
90	0.8444	0.8661	0.1270	0.8889	0.2222
100	0.8389	0.8091	0.1111	0.7778	0.1944

Tabella 11: Risultati ottenuti dalla SVM sporcando le feature migliori

4 Adult Income Dataset


Il dataset vuole mostrare come il reddito annuo di un individuo dipende da diversi fattori. In modo intuitivo, è influenzato dal livello di istruzione, dall'età, dal genere, dall'occupazione e così via.

4.1 Descrizione dataset

Il dataset è composto da **15 colonne** e **48842 righe**.


Nome Variabile	Descrizione
age	Età dell'individuo
workclass	Tipo di impiego
fnlwgt	Peso del campione censuario
education	Livello di istruzione, codificato come stringa
educational-num	Livello di istruzione, codificato come numero
marital-status	Stato civile
occupation	Occupazione
relationship	Relazione familiare
race	Razza
gender	Genere
capital-gain	Guadagni di capitale
capital-loss	Perdite di capitale
hours-per-week	Ore lavorate a settimana
native-country	Paese di origine
income	Variabile target (reddito annuo)

La distribuzione del target è: **76% $\geq$ 50K**, **24% $<$ 50K**.



In quanto ridondante con `educational-number`, abbiamo rimosso la feature `education`.

Attraverso il calcolo della Mutual Information per le varie feature, otteniamo una classifica, dalla più importante alla meno importante.



4.2 Risultati

4.2.1 Decision Tree

Prima di applicare il rumore, il Decision Tree è stato addestrato su un training set bilanciato mediante undersampling della classe maggioritaria. Il test set è stato invece mantenuto inalterato, così da valutare il modello sulla distribuzione originale dei dati. I risultati sono riportati nella Tabella 12.

Classe	Precision	Recall	F1-score	Supporto
0	0.95	0.77	0.85	11233
1	0.53	0.88	0.66	3420
Macro avg	0.74	0.82	0.76	14653
Weighted avg	0.86	0.79	0.81	14653

Tabella 12: Risultati del Decision Tree sull'Adult Income Dataset dopo l'undersampling del training set. L'accuracy complessiva è pari a 0.79.

L'undersampling consente al modello di riconoscere l'88% delle osservazioni della classe 1, ottenendo una balanced accuracy di circa 0.82. La precision della classe positiva si ferma tuttavia a 0.53: il maggiore recall viene quindi

ottenuto al costo di un numero consistente di falsi positivi. L'accuracy pari a 0.79 deve essere letta insieme alle metriche per classe, poiché il test set mantiene lo sbilanciamento originale.

Successivamente è stata valutata la robustezza dell'ensemble di Decision Tree applicando rumore alle feature meno informative: `hours-per-week`, `fnlwgt`, `capital-loss`, `gender`, `workclass`, `native-country` e `race`. Nella procedura implementata, le prime tre e `native-country` sono trattate come continue, mentre `gender`, `workclass` e `race` sono trattate come categoriche.

Con il dataset non corrotto, la migliore configurazione utilizza una profondità massima pari a 7, pesi di classe bilanciati e `ccp_alpha = 0.00020096`. Le prestazioni di riferimento sono riportate nella Tabella 13.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)	Macro F1	Weighted F1
0%	0.8108	0.8202	0.5712	0.8383	0.6795	0.7726	0.8212

Tabella 13: Prestazioni di riferimento dell'ensemble di Decision Tree prima della corruzione delle feature meno informative dell'Adult Income Dataset.

La matrice di confusione è $\begin{bmatrix} 8941 & 2206 \\ 567 & 2939 \end{bmatrix}$. Il modello riconosce quindi 2939 dei 3506 esempi della classe 1, raggiungendo un recall pari a 0.84; la precision pari a 0.57 segnala tuttavia la presenza di 2206 falsi positivi.




Figura 7: Robustezza dell'ensemble di Decision Tree al crescere del rumore applicato alle feature meno informative dell'Adult Income Dataset.

La Figura 7 mostra che accuracy, balanced accuracy e F1-score rimangono complessivamente stabili lungo l'intero intervallo di rumore. Dal 40% in poi il recall diminuisce, mentre la precision aumenta: il modello produce meno pre-

dizioni positive, riducendo i falsi positivi ma perdendo parte della capacità di individuare la classe 1. Non emerge comunque un deterioramento progressivo delle prestazioni complessive, indicando una buona robustezza rispetto alla corruzione di questo gruppo di feature.

Il secondo esperimento applica il rumore alle feature più informative: **relationship**, **marital-status**, **capital-gain**, **educational-num**, **age**, **occupation** e **hours-per-week**. Nella procedura implementata, **relationship** e **marital-status** sono trattate come categoriche, mentre le altre feature sono trattate come continue. La configurazione e le metriche allo 0% di rumore coincidono con quelle riportate nella Tabella 13, confermando una baseline comune ai due esperimenti.




Figura 8: Robustezza dell'ensemble di Decision Tree al crescere del rumore applicato alle feature più informative dell'Adult Income Dataset.

La Figura 8 mostra una maggiore sensibilità rispetto al primo gruppo. Fino al 50% le metriche cambiano in modo relativamente graduale; oltre questa soglia recall e precision diventano fortemente instabili e l'F1-score diminuisce da circa 0.68 a 0.55. In particolare, al 100% il recall scende a circa 0.45, indicando che il modello non riconosce più della metà degli esempi della classe positiva.

Il confronto tra i due grafici conferma quindi il ruolo della Mutual Information: la corruzione delle feature meno informative produce variazioni contenute, mentre il rumore sulle feature più informative altera maggiormente l'equilibrio tra precision e recall. L'accuracy rimane relativamente elevata anche nei casi peggiori, ma non è sufficiente per descrivere il deterioramento della classe minoritaria, che emerge più chiaramente dall'F1-score.

**NOTA DA VERIFICARE: TIPO DELLE FEATURE
CATEGORICHE**

Il codice identifica **native-country** e **occupation** come variabili continue perché, dopo la codifica numerica, presentano più valori della soglia usata per riconoscere le categorie. Entrambe sono però semanticamente categoriche; prima della versione finale è opportuno correggere la lista delle feature categoriche e ripetere entrambi gli esperimenti.

4.2.2 Neural Network

Il primo esperimento sulla rete neurale applica il rumore alle feature meno informative: **hours-per-week**, **fnlwgt**, **capital-loss**, **gender**, **workclass**, **native-country** e **race**. Per ogni livello di rumore vengono addestrate tre reti su campioni bootstrap e le probabilità prodotte vengono mediate per ottenere la predizione finale.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.2978	0.5341	0.2525	0.9872	0.4022
10%	0.7757	0.5332	0.9228	0.0682	0.1270
20%	0.7919	0.6377	0.6177	0.3420	0.4402
30%	0.7972	0.6237	0.6777	0.2909	0.4071
40%	0.3294	0.5536	0.2609	0.9835	0.4124
50%	0.7884	0.5658	0.8574	0.1389	0.2391
60%	0.4653	0.6307	0.3028	0.9478	0.4589
70%	0.7949	0.5788	0.8848	0.1643	0.2771
80%	0.7947	0.6317	0.6427	0.3192	0.4265
90%	0.7836	0.6368	0.5777	0.3554	0.4400
100%	0.7965	0.6191	0.6830	0.2790	0.3961

Tabella 14: Prestazioni dell'ensemble di reti neurali al crescere del rumore sulle feature meno informative dell'Adult Income Dataset.




Figura 9: Robustezza dell'ensemble di reti neurali al crescere del rumore applicato alle feature meno informative dell'Adult Income Dataset.

La Figura 9 evidenzia oscillazioni molto ampie e prive di un andamento progressivo. Allo 0%, al 40% e al 60% il recall è prossimo a 1 ma la precision è molto bassa; in tali condizioni la rete classifica come positivi gran parte dei campioni. Agli altri livelli accade spesso il contrario: accuracy e precision aumentano, mentre il recall crolla. Il modello alterna quindi due comportamenti estremi e non mostra una robustezza stabile rispetto al rumore.

L'accuracy, compresa tra 0.30 e 0.80, è particolarmente fuorviante in questo caso. Balanced accuracy e F1-score rimangono molto più contenuti e confermano che nessuna delle due modalità di predizione offre un buon equilibrio tra le classi. Le differenze osservate non possono essere attribuite con sicurezza al livello di rumore, poiché risultano dominate dall'instabilità della pipeline di addestramento.

Il secondo esperimento applica il rumore alle feature più informative: **relationship**, **marital-status**, **capital-gain**, **educational-num**, **age**, **occupation** e **hours-per-week**. I risultati sono riportati nella Tabella 15.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.7957	0.5953	0.7645	0.2111	0.3308
10%	0.7766	0.5348	0.9328	0.0713	0.1325
20%	0.7932	0.5797	0.8315	0.1703	0.2827
30%	0.3966	0.5926	0.2800	0.9683	0.4344
40%	0.7934	0.6271	0.6425	0.3080	0.4164
50%	0.2660	0.5144	0.2447	0.9906	0.3924
60%	0.7686	0.5165	1.0000	0.0331	0.0641
70%	0.7686	0.5172	0.9462	0.0351	0.0677
80%	0.7765	0.5344	0.9425	0.0702	0.1306
90%	0.7840	0.5514	0.9295	0.1052	0.1891
100%	0.7747	0.5312	0.9184	0.0642	0.1200

Tabella 15: Prestazioni dell'ensemble di reti neurali al crescere del rumore sulle feature più informative dell'Adult Income Dataset.




Figura 10: Robustezza dell'ensemble di reti neurali al crescere del rumore applicato alle feature più informative dell'Adult Income Dataset.

Anche la Figura 10 mostra transizioni improvvise tra comportamenti opposti. Al 30% e al 50% il recall è prossimo a 1, ma la precision e l'accuracy crollano; dal 60% in poi la precision supera 0.91 mentre il recall rimane inferiore a 0.11. In quest'ultima condizione la rete predice raramente la classe positiva e ne riconosce soltanto una piccola parte.

L'F1-score non supera 0.44 e, oltre il 60% di rumore, rimane particolarmente basso. I due esperimenti confermano quindi l'instabilità della rete, ma non consentono un confronto affidabile tra feature più e meno informative: le baseline allo 0% sono differenti e le oscillazioni non seguono il livello di corruzione. Le

conclusioni sull'effetto della Mutual Information devono essere rimandate alla riesecuzione controllata indicata nel riquadro seguente.

ATTENZIONE: RISULTATI DELLA RETE NEURALE DA RICALCOLARE

La funzione dell'esperimento progressivo non applica `RobustScaler`, nonostante feature come `fnlwgt` abbiano scale molto diverse dalle altre.

Inoltre, il bootstrap usa `np.random.choice` senza fissare il seed di NumPy. Prima della versione finale occorre applicare lo scaler usando solo il training set, fissare tutti i seed e ripetere ogni configurazione più volte, riportando media e deviazione standard. Resta inoltre da correggere il tipo di `native-country` e `occupation`, che devono essere trattate come categoriche.

4.2.3 SVM

Il primo esperimento con la SVM applica il rumore alle feature meno informative: `hours-per-week`, `fnlwgt`, `capital-loss`, `gender`, `workclass`, `native-country` e `race`. Per ogni livello di corruzione vengono addestrate tre SVM con kernel RBF su campioni bootstrap differenti; le predizioni vengono aggregate mediante voto di maggioranza.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.7980	0.5933	0.8167	0.2008	0.3223
10%	0.7972	0.5932	0.8036	0.2019	0.3228
20%	0.7970	0.5937	0.7969	0.2037	0.3244
30%	0.7967	0.5936	0.7912	0.2042	0.3246
40%	0.8000	0.5942	0.8485	0.1997	0.3233
50%	0.7994	0.5939	0.8403	0.1997	0.3227
60%	0.7968	0.5936	0.7936	0.2039	0.3245
70%	0.7996	0.5940	0.8424	0.1997	0.3228
80%	0.7969	0.5935	0.7958	0.2034	0.3239
90%	0.7984	0.5941	0.8187	0.2022	0.3243
100%	0.7988	0.5937	0.8298	0.2002	0.3226

Tabella 16: Prestazioni dell'ensemble di SVM al crescere del rumore sulle feature meno informative dell'Adult Income Dataset.




Figura 11: Robustezza dell'ensemble di SVM al crescere del rumore applicato alle feature meno informative dell'Adult Income Dataset.

La Figura 11 mostra metriche pressoché costanti per tutti i livelli di rumore. L'accuracy rimane intorno a 0.80, la balanced accuracy a 0.59 e l'F1-score a 0.32; non emerge quindi alcun effetto progressivo della corruzione su questo gruppo di feature.

Questa stabilità non corrisponde tuttavia a prestazioni equilibrate. La precision della classe 1 è elevata, tra 0.79 e 0.85, ma il recall rimane vicino a 0.20: il modello produce poche predizioni positive e non riconosce circa l'80% degli individui con reddito superiore a 50K. L'accuracy risulta pertanto influenzata dalla prevalenza della classe 0 e sovrastima la qualità complessiva del classificatore.

Il secondo esperimento applica il rumore alle feature più informative: **relationship**, **marital-status**, **capital-gain**, **educational-num**, **age**, **occupation** e **hours-per-week**. I valori numerici, recuperati dall'output del notebook, sono riportati nella Tabella 17.

Rumore	Accuracy	Balanced Acc.	Precision (1)	Recall (1)	F1 (1)
0%	0.7996	0.5939	0.8432	0.1994	0.3225
10%	0.7972	0.5932	0.8036	0.2019	0.3228
20%	0.7970	0.5916	0.8115	0.1977	0.3179
30%	0.7962	0.5907	0.8014	0.1968	0.3160
40%	0.7972	0.5919	0.8119	0.1982	0.3187
50%	0.7963	0.5926	0.7911	0.2019	0.3217
60%	0.7931	0.5919	0.7451	0.2059	0.3227
70%	0.7945	0.5918	0.7664	0.2031	0.3211
80%	0.7945	0.5916	0.7676	0.2025	0.3205
90%	0.7941	0.5931	0.7528	0.2076	0.3255
100%	0.7935	0.5922	0.7484	0.2062	0.3233

Tabella 17: Prestazioni dell'ensemble di SVM al crescere del rumore sulle feature più informative dell'Adult Income Dataset.




Figura 12: Robustezza dell'ensemble di SVM al crescere del rumore applicato alle feature più informative dell'Adult Income Dataset.

La Figura 12 presenta un andamento quasi piatto anche per le feature più informative. Accuracy, balanced accuracy, recall e F1-score cambiano soltanto di pochi millesimi; la precision diminuisce moderatamente, passando da circa 0.84 a 0.75, senza produrre un miglioramento sostanziale del recall, che rimane vicino a 0.20.

I due gruppi producono quindi risultati sostanzialmente equivalenti e non mostrano la differenza di sensibilità attesa dalla Mutual Information. Tuttavia, considerata l'assenza di scaling nella funzione progressiva e il comportamento quasi costante delle predizioni, questa evidenza non è sufficiente per concludere che la SVM sia realmente robusta. Il confronto deve essere ripetuto con la pipeline corretta prima di formulare conclusioni definitive.

ATTENZIONE: RISULTATI SVM DA VERIFICARE

La funzione progressiva non applica `RobustScaler`; la grande scala di `fnlwt` può quindi dominare le distanze utilizzate dal kernel RBF e rendere il modello poco sensibile alle altre feature. Anche il bootstrap usa `np.random.choice` senza un seed NumPy esplicito. Occorre applicare lo scaling sul solo training set, fissare il seed, correggere il tipo di `native-country` e `occupation`, quindi rieseguire entrambi gli esperimenti prima della versione finale.

5 Confronto dati

6 Conclusioni